

## 1. 背景：


- 1.1 最早是由 Vladimir N. Vapnik 和 Alexey Ya. Chervonenkis 在1963年提出
- 1.2 目前的版本(soft margin)是由Corinna Cortes 和 Vapnik在1993年提出，并在1995年发表
- 1.3 深度学习（2012）出现之前，SVM被认为机器学习中近十几年来最成功，表现最好的算法

## 2. 机器学习的一般框架：

训练集 => 提取特征向量 => 结合一定的算法（分类器：比如决策树，KNN）=>得到结果


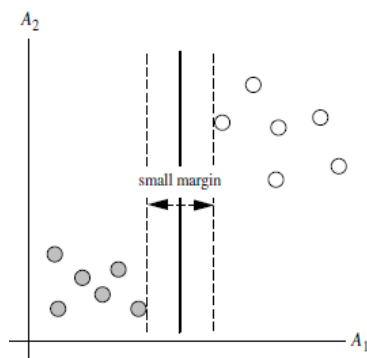
## 3. 介绍：

## 3.1 例子：



两类？哪条线最好？

## 3.2 SVM寻找区分两类的超平面（hyper plane），使边际(margin)最大





总共可以有多少个可能的超平面？无数条

如何选取使边际(margin)最大的超平面 (Max Margin Hyperplane)？

超平面到一侧最近点的距离等于到另一侧最近点的距离，两侧的两个超平面平行

## 3. 线性可区分(linear separable) 和 线性不可区分 (linear inseparable)







#### 4. 定义与公式建立

超平面可以定义为： $W \cdot X + b = 0$

$W$ : weight vectot,  $W = \{w_1, w_2, \dots, w_n\}$ ,  $n$  是特征值的个数

$X$ : 训练实例

$b$ : bias



##### 4.1 假设2维特征向量： $X = (x_1, x_2)$

把  $b$  想象为额外的 weight

超平面方程变为： $w_0 + w_1x_1 + w_2x_2 = 0$ .

所有超平面右上方的点满足： $w_0 + w_1x_1 + w_2x_2 > 0$ .

所有超平面左下方的点满足： $w_0 + w_1x_1 + w_2x_2 < 0$

调整weight, 使超平面定义边际的两边：


$$H_1: w_0 + w_1x_1 + w_2x_2 \geq 1 \text{ for } y_i = +1,$$

$$H_2: w_0 + w_1x_1 + w_2x_2 \leq -1 \text{ for } y_i = -1$$

综合以上两式, 得到: (1)

$$y_i(w_0 + w_1x_1 + w_2x_2) \geq 1, \forall i.$$

所有坐落在边际的两边的的超平面上的被称作“支持向量(support vectors)”

分界的超平面和 $H_1$ 或 $H_2$ 上任意一点的距离为  (i.e.: 其中 $\|W\|$ 是向量的范数(norm))

$$\text{If } W = \{w_1, w_2, \dots, w_n\} \text{ then } \sqrt{W \cdot W} = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}.$$

所以, 最大边际距离为: 

#### 5. 求解

##### 5.1 SVM如何找出最大边际的超平面呢(MMH) ?

利用一些数学推倒, 以上公式 (1) 可变为有限制的凸优化问题(convex quadratic optimization)

利用 Karush-Kuhn-Tucker (KKT)条件和拉格朗日公式，可以推出MMH可以被表示为以下“决定边界 (decision boundary)”

$$d(X^T) = \sum_{i=1}^l y_i \alpha_i X_i X^T + b_0,$$

其中，

是支持向量点 ( support vector)的类别标记 ( class label)

是要测试的实例


和 都是单一数值型参数，由以上提到的最有算法得出

是支持向量点的个数

5.2 对于任何测试（要归类的）实例，带入以上公式，得出的符号是正还是负决定

6. 例子：

$$g(\vec{x}) \geq 1, \quad \forall \vec{x} \in \text{class 1}$$
$$g(\vec{x}) \leq -1, \quad \forall \vec{x} \in \text{class 2}$$



## Example

